

视觉问答与多模态预训练模型技术演进综述

A Survey on the Evolution of Visual Question Answering and Vision-Language Pre-trained Models

2026 年 6 月 21 日

摘要

视觉问答 (Visual Question Answering, VQA) 要求模型根据图像内容回答自然语言问题, 是连接计算机视觉、自然语言处理与多模态推理的重要研究任务。其技术路线已由早期的卷积神经网络与循环神经网络组合, 逐步发展为基于注意力和区域特征的细粒度建模、多模态 Transformer 预训练、图文对比学习与统一视觉语言模型, 并进一步演化为具备开放式对话和复杂推理能力的多模态大语言模型。本文围绕这一演进过程, 对 Stacked Attention Network、Bottom-Up and Top-Down Attention、ViLBERT、LXMERT、ViLT、CLIP、BLIP、BLIP-2、LLaVA、Qwen2-VL、InternVL3 等代表性方法进行梳理, 从视觉表示、跨模态交互、训练目标、计算效率和任务适应性等角度展开比较。分析表明, 预训练规模和统一建模显著提高了模型的迁移能力, 但视觉幻觉、细粒度感知、复杂推理、评测可信度、训练成本与数据治理仍是制约实际应用的关键问题。最后, 本文讨论了高分辨率与长视频理解、可验证推理、轻量化训练以及可信评测等可能的发展方向。

关键词: 视觉问答; 多模态预训练; 视觉语言模型; 注意力机制; 多模态大语言模型

1 引言与研究背景

视觉问答的基本形式是: 给定一幅图像和一个与图像有关的自然语言问题, 模型生成准确、简洁的自然语言答案。Antol 等提出的大规模 VQA 数据集推动了该任务的标准化研究。与图像分类或图像描述相比, VQA 不仅要求模型识别图像中的对象, 还要根据问题选择相关视觉区域, 并完成属性判断、计数、空间关系分析和常识推断等过程[1]。因此, VQA 常被视为检验机器能否联合理解视觉与语言信息的重要任务。

VQA 的研究价值主要体现在三个方面。第一, 它建立了视觉感知与语言交互之间的直接联系, 使模型能够以自然语言形式接受人类查询。第二, 不同问题会关注同一图像中的不同信息, 这要求模型具备目标选择和跨模态对齐能力。第三, VQA 可服务于辅助视觉、智能教育、人机交互、机器人感知和多媒体检索等应用。Kafle 和 Kanan 指出, VQA 系统的性能不仅取决于模型结构, 还受到数据集偏差、答案分布和评价指标的显著影响[2]。例如, 模型可能利用“香蕉通常是黄色”等语言先验, 在未充分观察图像时也给出看似合理的答案。因此, 衡量 VQA 能力不能只观察总体准确率, 还需要考察模型是否真正依赖视觉证据。

从技术发展看, VQA 经历了由任务专用模型向通用视觉语言模型转变的过程。早期工作分别提取图像和问题特征, 再通过拼接、逐元素运算或双线性池化进行融合; 随后, 注意力机制使模型能够根据问题定位关键区域; 多模态 Transformer 进一步在大规模图文数据上学习通用对齐关系; 近年来, 多模态大语言模型则将视觉编码器、连接模块和大型语言模型组合起来, 使 VQA 从短答案预测扩展为开放式对话与多步推理。下文按照这一脉络梳理代表性研究。

2 研究方法的历史演进

2.1 早期 VQA: CNN/RNN + 特征融合

早期 VQA 系统一般采用双分支结构。视觉分支使用在图像分类数据上预训练的卷积神经网络提取全局图像向量，语言分支使用循环神经网络或长短期记忆网络编码问题，随后将两种特征映射到共同空间并进行答案分类。这一框架结构直观、训练流程清晰，但全局视觉向量会压缩空间信息，而简单拼接或逐元素乘法难以充分表达视觉维度与语言维度之间的高阶关系。

Stacked Attention Network (SAN) 在此基础上引入多层注意力。该方法把问题表示作为查询，反复在图像特征图上搜索与答案有关的区域，使模型能够逐层聚焦视觉线索[3]。SAN 说明，同一图像不应对所有问题使用固定表示：询问颜色时应关注目标表面，询问位置时则应关注目标及其周围环境。多次注意力更新也为后续跨模态推理提供了早期思路。

为了提高特征融合的表达能力，Fukui 等提出 Multimodal Compact Bilinear Pooling (MCB)。双线性池化能够捕获视觉与语言特征的成对交互，但直接计算外积会带来极高维度和存储开销。MCB 通过紧凑随机映射近似外积，在控制计算量的同时保留较丰富的二阶交互信息，并可同时用于注意力计算与答案预测[4]。这类方法提升了融合质量，但仍高度依赖任务专用结构，且视觉表示通常缺少明确的对象级语义。

2.2 注意力机制与区域特征

注意力机制的核心作用是让模型回答“应该看哪里”。SAN 使用问题引导的多层注意力，在卷积特征图上逐步筛选相关位置[3]；它比全局特征更有针对性，但网格特征中的单元并不一定与真实物体边界对应，复杂场景中容易把多个对象混合在一起。

Bottom-Up and Top-Down Attention 将对象检测器产生的区域特征引入视觉语言任务。其 bottom-up 部分通过目标检测模型提出具有明确对象或显著区域含义的候选区域，top-down 部分再依据问题对这些区域赋予不同权重[5]。相较规则网格特征，区域表示更适合处理“哪个人拿着球”“桌上有几个杯子”等对象关系问题，也推动了 VQA 模型从粗粒度图像编码向对象级建模发展。

区域特征路线的优势是可解释性较强，注意力权重可以对应到候选框；其不足是训练和推理依赖额外的目标检测器，视觉类别及区域质量受到检测器训练数据限制。检测阶段还会增加系统复杂度，并可能遗漏文字、背景或非典型目标。此后研究逐渐尝试以端到端视觉 Transformer 和大规模预训练取代固定区域提取流程。

2.3 多模态 Transformer 预训练

Transformer 的自注意力机制为统一建模视觉与语言序列提供了基础。ViLBERT 采用双流结构，分别处理区域视觉特征和文本词元，并通过协同注意力层交换跨模态信息。模型先在大规模图文对上预训练，再迁移到 VQA、图文检索和指代表达理解等任务[6]。这种“预训练加微调”的范式降低了每个任务从头学习跨模态对齐的成本。

LXMERT 将模型划分为语言编码器、对象关系编码器和跨模态编码器，并设置掩码语言建模、掩码对象预测、图文匹配和图像问答等多种预训练目标[7]。与单纯的任务监督相比，多目标预训练能够同时学习模态内部结构和模态之间的对应关系。然而，ViLBERT 与 LXMERT 仍依赖预先提取的区域特征，整体系统包含检测器和 Transformer 两套计算过程。

ViLT 进一步简化视觉输入，直接把图像切分为 patch 并与文本词元共同送入 Transformer，不再使用卷积骨干或区域监督[8]。其主要贡献并非单纯扩大模型规模，而是显著减少视觉特征提取开销，使计算资源更多用于跨模态交互。ViLT 展示了轻量视觉嵌入的可行性，但简单 patch 表示在细粒度对象定位和高分辨率场景中仍可能损失局部信息。

2.4 图文对比学习与统一视觉语言模型

CLIP 通过大规模图文对上的对比学习，将匹配的图像和文本拉近、非匹配样本推远，从而获得具有较强迁移能力的视觉表示[9]。它把自然语言类别描述转化为分类器，使视觉模型能够进行零样本识别。对 VQA 而言，CLIP 证明了开放互联网图文监督可以提供广泛的视觉语义知识，但其对比目标主要学习全局对应关系，本身并不直接完成问题条件下的答案生成。

BLIP 试图统一视觉语言理解与生成。该方法通过图像编码器和多功能 Transformer 同时支持图文对比、图文匹配与语言生成，并采用 captioner 生成合成描述、filter 过滤噪声数据的自举机制，提高网络图文数据的可用性[10]。在 VQA 中，BLIP 可以根据图像和问题生成答案，也能迁移到检索、描述生成等任务。相较纯对比学习，统一目标增强了模型对生成任务的适应性。

BLIP-2 将冻结的视觉编码器与冻结的大语言模型连接起来，并设计轻量的 Querying Transformer (Q-Former) 提取对语言模型最有价值的视觉信息[11]。两阶段预训练先完成视觉语言表示学习，再完成视觉到语言的生成对齐。这一设计减少了端到端训练大型模型的成本，也确立了“视觉编码器 + 连接模块 + 大语言模型”的主流架构。不过，冻结组件之间仍可能存在表示差异，连接模块能否保留细粒度视觉证据成为关键问题。

2.5 近期前沿：MLLM / LVLM

视觉指令微调使视觉语言模型能够按照自然语言指令完成开放式任务。LLaVA 将视觉编码器与大语言模型连接，并利用语言模型生成的多模态指令数据进行训练，使模型具备多轮视觉对话与解释能力[12]。此时，VQA 不再局限于从固定答案集合中分类，而是成为多模态助手的一项基础能力。

MM1 从预训练方法角度系统分析图像编码器、视觉语言连接器以及数据组成的影响，强调图文描述数据、交错图文数据与纯文本数据的合理配比，并研究密集模型和混合专家模型的扩展规律[13]。这一工作说明，模型能力不仅由参数量决定，数据类型和训练阶段设计同样关键。

Qwen2-VL 引入动态分辨率处理，使不同尺寸的图像能够以可变数量的视觉 token 表示，并采用多模态旋转位置编码统一建模文本、图像和视频中的位置信息[14]。Qwen2.5-VL 在此基础上加强目标定位、文档结构解析、长视频时间理解和视觉智能体能力，使模型能够处理更复杂的真实输入[15]。这些改进拓宽了 VQA 的对象：问题可以针对高分辨率页面、视频片段或界面操作，而不再只针对单张自然图像。

InternVL3 探索原生多模态预训练，在同一预训练阶段联合学习多模态与纯语言能力，并结合可变视觉位置编码、监督微调、偏好优化和测试时扩展策略[16]。这代表近期开放模型从“给文本模型追加视觉模块”转向更统一的训练范式。总体而言，MLLM/LVLM 提高了开放世界泛化和交互能力，但自由生成也使幻觉、答案冗余和事实验证问题更加突出。

3 方法对比分析

不同阶段的方法并非简单替代关系，而是在视觉表示、跨模态交互和训练方式上逐步扩展。SAN 以问题引导多次空间注意力，适合展示模型如何逐步定位答案线索[3]；Bottom-Up and Top-Down Attention 把视觉单元从规则网格提升为对象区域，加强对象级关系建模[5]；ViLT 取消检测器，以图像 patch 和文本词元的联合 Transformer 换取更简洁的端到端计算[8]；BLIP 通过统一理解与生成目标以及数据自举，提高多任务迁移能力[10]；Qwen2-VL 则依托动态分辨率和大语言模型，将 VQA 扩展到高分辨率、视频和开放式指令场景[14]。

方法范式	代表工作	核心机制	主要优势	主要局限
空间注意力	SAN [3]	问题引导的多层注意力反复查询图像特征	结构清晰，能逐步聚焦关键区域	依赖网格特征，对真实对象边界建模有限
区域注意力	Bottom-Up/Top-Down [5]	检测器提出区域，问题对区域加权	对象级语义明确，适合关系与计数问题	依赖外部检测器，流程复杂且可能漏检
轻量多模态 Transformer	ViLT [8]	图像 patch 与文本词元直接联合编码	端到端、视觉前端开销低	高分辨率和细粒度定位能力受输入 token 限制
统一视觉语言预训练	BLIP [10]	对比、匹配、生成目标与数据自举	同时支持理解和生成，迁移性较好	训练数据质量与生成偏差仍会影响结果
多模态大语言模型	Qwen2-VL [14]	动态分辨率、统一位置编码与语言生成	输入类型广，支持开放式问答与视频理解	推理成本较高，可能产生视觉幻觉

从视觉表示看，技术路线由全局卷积特征发展到网格注意力、对象区域、图像 patch 和动态分辨率视觉 token；从融合方式看，由静态拼接和双线性交互发展到跨模态注意力与统一序列建模；从训练方式看，由单一数据集监督发展到大规模预训练、指令微调和偏好优化；从输出形式看，则由固定答案分类逐渐转向自然语言生成。统一模型拥有更好的任务覆盖面，但专用 VQA 模型在资源受限、答案空间稳定和评价要求明确的场景中仍具有速度快、结果易控制的优势。

因此，方法选择应根据任务目标进行权衡。若数据规模小且答案类型固定，可采用较轻量的专用模型；若需要跨数据集迁移、开放式回答或多轮交互，则预训练视觉语言模型更合适；若输入包含高分辨率文档、视频或复杂指令，MLLM 更具扩展性，但必须同步考虑推理成本、输出约束和可信性验证。

4 当前局限与未来方向

4.1 数据偏差与评测可信度

VQA 数据集集中的问题模板和答案频率会形成明显语言先验。模型可能依赖训练集统计规律，而不是读取视觉证据。Kafle 和 Kanan 对数据集、评价指标和算法的分析表明，仅用总体准确率难以区分真正的多模态理解与捷径学习[2]。未来评测应增加反事实样本、分布外测试和成对一致性检查，并分别报告感知、知识、推理与鲁棒性能力。

4.2 细粒度感知与复杂推理

现有模型在小目标、精确计数、空间关系、遮挡场景和密集文字方面仍容易出错。Qwen2-VL 的动态分辨率机制缓解了固定输入尺寸导致的信息压缩问题[14]，InternVL3 的可变视觉位置编码则面向更长的多模态上下文[16]。但提高分辨率会迅速增加视觉 token 数量和计算开销。未来需要研究内容自适应采样、局部放大、分层视觉编码以及检索式视觉记忆，使模型在控制成本的同时保留关键细节。

4.3 幻觉、可解释性与可验证回答

生成式模型可能在视觉证据不足时依据语言先验补全细节，形成“答案流畅但图像中并不存在”的视觉幻觉。模型给出的自然语言解释也不一定反映真实推理过程。未来可以把答案与区域定位、对象引用或证据框绑定，并引入拒答机制和置信度校准。对于计数、图表和文档问题，可让模型调用检测、OCR 或计算工具，再用可检查的中间结果支持最终回答。

4.4 数据规模、训练成本与开放治理

MM1 的分析表明，图文描述、交错图文和纯文本数据的组合会显著影响模型能力[13]；InternVL3 进一步采用统一预训练、偏好优化和测试时扩展策略[16]。这些路线提高了上限，也带来数据来源不透明、版权与隐私风险、训练能耗高和实验难复现等问题。未来研究应更完整地披露数据构成和过滤规则，建立可审计的数据治理流程，同时发展参数高效微调、蒸馏、量化与稀疏计算，降低模型训练和部署门槛。

4.5 面向真实场景的持续发展

未来 VQA 将进一步从静态图像问答扩展到长视频、三维空间、文档理解和具身智能。Qwen2-VL 展示了统一处理图像与视频的可能性[14]，InternVL3 则体现了训练阶段与测试阶段协同扩展的趋势[16]。值得关注的方向包括：跨帧因果与时间推理、视觉定位和操作决策结合、外部知识检索、模型输出的事实校验，以及面向边缘设备的高效部署。研究目标也应从单纯追求榜单分数，转向构建能够在陌生环境中承认不确定性、引用视觉证据并稳定完成任务的系统。

5 结语

VQA 的技术演进反映了多模态人工智能从任务专用架构走向通用基础模型的过程。早期 CNN/RNN 和特征融合奠定了双模态建模框架，注意力与区域特征增强了问题相关的视觉选择能力，多模态 Transformer 预训练建立了可迁移的跨模态表示，CLIP、BLIP 与 BLIP-2 推动理解和生成目标逐步统一，而近期 MLLM/LVLM 则把 VQA 扩展到开放式对话、高分辨率图像、视频和智能体任务。

模型能力的提升并不意味着 VQA 已经得到彻底解决。当前系统仍需要在视觉证据利用、复杂推理、幻觉控制、评测设计和计算效率之间取得平衡。未来更有价值的进展，应当既提高模型在开放场景中的能力，也使答案来源可追踪、错误可识别、训练与部署成本可接受。只有把感知、推理和可信性共同纳入设计，VQA 才能从实验指标走向稳定可靠的实际应用。

参考文献

- [1] Antol, S., Agrawal, A., Lu, J., et al. VQA: Visual Question Answering. ICCV, 2015.
- [2] Kafle, K., & Kanan, C. Visual Question Answering: Datasets, Algorithms, and Future Challenges. Computer Vision and Image Understanding, 2017.
- [3] Yang, Z., He, X., Gao, J., Deng, L., & Smola, A. Stacked Attention Networks for Image Question Answering. CVPR, 2016.
- [4] Fukui, A., Park, D. H., Yang, D., Rohrbach, A., Darrell, T., & Rohrbach, M. Multimodal Compact Bilinear Pooling for Visual Question Answering and Visual Grounding. EMNLP, 2016.
- [5] Anderson, P., He, X., Buehler, C., et al. Bottom-Up and Top-Down Attention for Image Captioning and Visual Question Answering. CVPR, 2018.
- [6] Lu, J., Batra, D., Parikh, D., & Lee, S. ViLBERT: Pretraining Task-Agnostic Visiolinguistic Representations for Vision-and-Language Tasks. NeurIPS, 2019.
- [7] Tan, H., & Bansal, M. LXMERT: Learning Cross-Modality Encoder Representations from Transformers. EMNLP, 2019.
- [8] Kim, W., Son, B., & Kim, I. ViLT: Vision-and-Language Transformer Without Convolution or Region Supervision. ICML, 2021.
- [9] Radford, A., Kim, J. W., Hallacy, C., et al. Learning Transferable Visual Models From Natural Language Supervision. ICML, 2021.
- [10] Li, J., Li, D., Xiong, C., & Hoi, S. BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation. ICML, 2022.
- [11] Li, J., Li, D., Savarese, S., & Hoi, S. BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models. ICML, 2023.
- [12] Liu, H., Li, C., Wu, Q., & Lee, Y. J. Visual Instruction Tuning. NeurIPS, 2023.
- [13] McKinzie, B., Gan, Z., Fauconnier, J.-P., et al. MM1: Methods, Analysis & Insights from Multimodal LLM Pre-training. ECCV, 2024.
- [14] Wang, P., Bai, S., Tan, S., et al. Qwen2-VL: Enhancing Vision-Language Model's Perception of the World at Any Resolution. arXiv, 2024.
- [15] Bai, S., Chen, K., Liu, X., et al. Qwen2.5-VL Technical Report. arXiv, 2025.
- [16] Zhu, J., Wang, W., Chen, Z., et al. InternVL3: Exploring Advanced Training and Test-Time Recipes for Open-Source Multimodal Models. arXiv, 2025.